

kylin-memory-bench

让长期记忆的判断落到可复查的回复、记忆记录与实际文件。

问题

只问智能体“还记得吗”，不足以发现它把旧值继续用于任务、混淆相似实体，或把临时信息错误地写进长期记忆。评测必须跨会话，并对真实行动留证。

六项能力

01 长期保持	02 记忆调用
隔开干扰后回忆代号	召回项目负责人和格式
03 动态更新	04 相近区分
更正后弃用旧联系人	不交换相近任务日期
05 边界识别	06 任务复用
临时验证码不持久化	按旧偏好写出真实文件

运行链

任务 JSON → 两款智能体适配器 → 原始回复 / 帧 / 文件 → 确定性检查项 → 六维分数、逐项原因和 SVG 雷达图。缺证据不得分；口头称已写文件，仍须核对文件内容。

本机读数

两个虚构替身走完整 CLI：参考替身六维 100，故意出错的替身总分 19.45。更新旧值、禁存验证码和错误分隔符均被扣分。这只验证流水线，不是 KylinBot 或 OpenClaw 的成绩。

从证据到可解释分数

四类检查：回复 JSON 字段、产物 JSON 字段、禁用值是否出现在回复，以及禁用值是否出现在可观察的记忆文件。每项报告 pass / fail / missing 与来源。六维各自归一，再取均值。

任务书评分项

任务定义与通用性	15%	六项跨会话任务与统一接口
数据设计质量	25%	虚构样本、旧值与禁用值、行动核验
自动评分能力	25%	原始证据、结构化判断与原因
稳定性与可复现性	15%	指纹、隔离输出、运行 ID、合同测试
指标完整性	10%	六维分、总分、JSON、雷达图
创新与工程落地	10%	回复 + 记忆 + 文件联合裁决

真实运行入口

KylinBot 通过 Gateway 的 kylinbot.v1 WebSocket 对话；OpenClaw 通过带固定 session key 的 agent CLI。run-live.sh 从同一数据集批量运行两个配置，产出完整结果和雷达图。deb 构建脚本随仓提供。

当前边界与下一发

公开代码与替身样例已具备。仍须在 openKylin 云桌面安装两款真实智能体、核实记忆目录和包依赖、跑完整批次，并录 3 – 5 分钟真实桌面演示。六维目前各一条任务，后续扩充多样本与独立重复运行。

代码、任务、评分器与方案：github.com/logxio/kylin-memory-bench