

记忆状态取证评测

把跨会话回复、可观察记忆和实际文件逐项核对：智能体没说出口的禁存值，也可能已经进入记忆。缺证据不得分。

问题

只问智能体“还记得吗”，不足以发现它把旧值继续用于任务、混淆相似实体，或把临时信息错误地写进长期记忆。评测必须跨会话，并对真实行动留证。

六项能力

01 长期保持 隔开干扰后回忆代号	02 记忆调用 召回项目负责人和格式
03 动态更新 更正后弃用旧联系人	04 相近区分 不交换相近任务日期
05 边界识别 临时验证码不持久化	06 任务复用 按旧偏好写出真实文件

运行链

任务 JSON → 两款智能体适配器 → 原始回复 / 帧 / 文件 → 确定性检查项 → 六维分数、逐项原因和 SVG 雷达图。缺证据不得分；口头称已写文件，仍须核对文件内容。

openKylin 3.0 / 12 例真实重复运行

KylinBot 0.7.5 与 OpenClaw 2026.9.6 双实装；v0.2.2 发行包已在 openKylin 3.0 经 apt 安装。下表是两款真实适配器连续三批运行同一数据与配置，每批每款 12 例、28 步；批前恢复并核验干净记忆状态。

批次 / run ID	KylinBot: 分数 / 完成 / 超时	OpenClaw: 分数 / 完成 / 超时
1 / b72c1361f53e	40.28 / 28/28 / 0	34.72 / 28/28 / 0
2 / 0c2f2492a6fb	36.11 / 28/28 / 0	34.72 / 28/28 / 0
3 / 9365dedf1939	31.95 / 28/28 / 0	47.22 / 28/28 / 0

三批总分均值 / 样本标准差：KylinBot 36.11 / 4.17，完成 84/84 步、0 次 TimeoutError；OpenClaw 38.89 / 7.22，完成 84/84 步、0 次 TimeoutError。均为智能体分数，非评委分。

本轮 4 分 06 秒演示先说明记忆状态取证评测与公开禁存案例，再接 openKylin 桌面安装版本、三批结果、雷达图与独立现场小案例；开头卡片不是新跑批。

从证据到可解释分数

四类检查：回复 JSON 字段、产物 JSON 字段、禁用值是否出现在回复或文件，以及禁用值是否进入可观察的记忆文件或 SQLite 记录。每项报告 pass / fail / missing 与来源。六维各自归一，再取均值。

任务书评分项

任务定义与通用性	15%	六项跨会话任务与统一接口
数据设计质量	25%	六维各两例、虚构变体、行动核验
自动评分能力	25%	原始证据、结构化判断与原因
稳定性与可复现性	15%	三批同指纹复跑、隔离、错误与完成率
指标完整性	10%	六维分、总分、JSON、雷达图
创新与工程落地	10%	回复 + 记忆 + 文件联合裁决

重复口径与边界

n=3 批；每批每维 2 例，两个智能体各 28 步。只汇总同一数据、各智能体相同配置指纹及相同评分器版本的完整运行；逐维和总分报告均值、样本标准差，逐步统计完成率与 TimeoutError。历史六例、旧 v0.2.0 批次和替身结果不混算。v0.2.2 保持 v0.2.1 的 JSON 围栏评分口径，改进客户端超时控制。三批前均恢复并核验干净记忆状态；一次隔离预检失败单独保留，不纳入三批。仍仅同一台 VM、每维两例，OpenClaw 温度未显式固定；不能认定稳定排名或统计显著性。完整原始证据私下保留。

自己重算三批六维

公开去敏输入覆盖三批、两款智能体、六维各两例；用仓内评分器重算 72 个案例判定、150 项检查及原因、六维和三批摘要，并对照公开报告。完整原件私下保存。

python3 scripts/replay-full-scenarios.py (Python 3.10+)

版本与参与

v0.2.2 Release 与 .deb、Ubuntu CI、三批摘要与逐项判定及原始哈希、贡献指南和 Issue 入口。历史 v0.2.1 离线重算另有固定报告，不写成新版真机重跑。