

kylin-memory-bench

让长期记忆的判断落到可复查的回复、记忆记录与实际文件。

问题

只问智能体“还记得吗”，不足以发现它把旧值继续用于任务、混淆相似实体，或把临时信息错误地写进长期记忆。评测必须跨会话，并对真实行动留证。

六项能力

01 长期保持	02 记忆调用
隔开干扰后回忆代号	召回项目负责人和格式
03 动态更新	04 相近区分
更正后弃用旧联系人	不交换相近任务日期
05 边界识别	06 任务复用
临时验证码不持久化	按旧偏好写出真实文件

运行链

任务 JSON → 两款智能体适配器 → 原始回复 / 帧 / 文件 → 确定性检查项 → 六维分数、逐项原因和 SVG 雷达图。缺证据不得分；口头称已写文件，仍须核对文件内容。

openKylin 3.0 真实运行

.deb 已在系统安装，KylinBot 0.7.5 与 OpenClaw 2026.9.6 均完成真实模型对话。首批六维全跑：KylinBot 25.00/100、OpenClaw 30.55/100，双方各 14 步、无适配错误。4 分 47 秒真实桌面视频展示安装环境、运行与报告；分数是智能体评测结果，非大赛评委分。

从证据到可解释分数

四类检查：回复 JSON 字段、产物 JSON 字段、禁用值是否出现在回复，以及禁用值是否进入可观察的记忆文件或 SQLite 记录。每项报告 pass / fail / missing 与来源。六维各自归一，再取均值。

任务书评分项

任务定义与通用性	15%	六项跨会话任务与统一接口
数据设计质量	25%	虚构样本、旧值与禁用值、行动核验
自动评分能力	25%	原始证据、结构化判断与原因
稳定性与可复现性	15%	指纹、隔离输出、运行 ID、合同测试
指标完整性	10%	六维分、总分、JSON、雷达图
创新与工程落地	10%	回复 + 记忆 + 文件联合裁决

真实运行入口

KylinBot 通过 Gateway 的 kylinbot.v1 WebSocket 对话；OpenClaw 通过固定 session key 的 agent CLI。run-live.sh 用同一任务集跑双智能体；公开仓提供 .deb 构建脚本、两批报告、雷达图与桌面视频。

当前边界与下一发

第二批加入 SQLite 只读观察，KylinBot / OpenClaw 为 33.33 / 30.55；KylinBot 有一步超时，只完成 13/14 步。两批顺序翻转，六维每维仅一例，不能据此判定稳定排名。下一发扩样本并量超时率与分数波动。

代码、两批报告、雷达图与视频：github.com/logxio/kylin-memory-bench