

kylin-memory-bench

让长期记忆的判断落到可复查的回复、记忆记录与实际文件。

问题

只问智能体“还记得吗”，不足以发现它把旧值继续用于任务、混淆相似实体，或把临时信息错误地写进长期记忆。评测必须跨会话，并对真实行动留证。

六项能力

01 长期保持

隔开干扰后回忆代号

03 动态更新

更正后弃用旧联系人

05 边界识别

临时验证码不持久化

02 记忆调用

召回项目负责人和格式

04 相近区分

不交换相近任务日期

06 任务复用

按旧偏好写出真实文件

运行链

任务 JSON → 两款智能体适配器 → 原始回复 / 帧 / 文件 → 确定性检查项 → 六维分数、逐项原因和 SVG 雷达图。缺证据不得分；口头称已写文件，仍须核对文件内容。

openKylin 3.0 / 12 例真实重复运行

KylinBot 0.7.5 与 OpenClaw 2026.9.6 双实装；v0.2.0 发行包已在 openKylin 经 apt 安装。相同数据与配置、批前恢复干净记忆状态；每批每款智能体运行 12 例、28 步。

批次 / run ID	KylinBot: 分数 / 完成 / 超时	OpenClaw: 分数 / 完成 / 超时
1 / 92ae7d35ea9f	31.95 / 21/28 / 3	31.94 / 26/28 / 2
2 / abe90652770c	40.28 / 28/28 / 0	34.72 / 28/28 / 0
3 / 5ad3c72309be	30.56 / 28/28 / 0	34.72 / 28/28 / 0

三批总分均值 / 样本标准差：KylinBot 34.26 / 5.26，完成 77/84 步、3 次 TimeoutError；OpenClaw 33.79 / 1.61，完成 82/84 步、2 次 TimeoutError。均为智能体分数，非评委分。

4 分 47 秒 openKylin 桌面视频展示真实双智能体环境与历史六例运行；上表 12 例复跑有独立的去敏报告与摘要。

从证据到可解释分数

四类检查：回复 JSON 字段、产物 JSON 字段、禁用值是否出现在回复或文件，以及禁用值是否进入可观察的记忆文件或 SQLite 记录。每项报告 pass / fail / missing 与来源。六维各自归一，再取均值。

任务书评分项

任务定义与通用性	15%	六项跨会话任务与统一接口
数据设计质量	25%	六维各两例、虚构变体、行动核验
自动评分能力	25%	原始证据、结构化判断与原因
稳定性与可复现性	15%	三批同指纹复跑、隔离、错误与完成率
指标完整性	10%	六维分、总分、JSON、雷达图
创新与工程落地	10%	回复 + 记忆 + 文件联合裁决

重复口径与边界

n=3 批；每批每维 2 例，两个智能体各 28 步。仅把同一数据和各智能体相同配置指纹的完整运行按批汇总，逐维与总分报告均值、样本标准差；逐步统计完成率与 TimeoutError。不同数据集、历史六例和替身结果不混算。

三批前均恢复并核验专用身份的干净记忆状态。仍只有同一台 VM、每维两例、三批观察；模型温度未显式固定，不能据此认定稳定排名、统计显著性或跨环境表现。原始证据私下保留，公开报告已去敏。

版本与参与

v0.2.0 Release 与 .deb、Ubuntu CI、三批去敏摘要、贡献指南与 Issue 入口。公开仓提供复跑命令与方法；CI 验证干净构建和替身，真实 openKylin 结果见报告。