

# kylin-memory-bench

让长期记忆的判断落到可复查的回复、记忆记录与实际文件。

## 问题

只问智能体“还记得吗”，不足以发现它把旧值继续用于任务、混淆相似实体，或把临时信息错误地写进长期记忆。评测必须跨会话，并对真实行动留证。

## 六项能力

### 01 长期保持

隔开干扰后回忆代号

### 03 动态更新

更正后弃用旧联系人

### 05 边界识别

临时验证码不持久化

### 02 记忆调用

召回项目负责人和格式

### 04 相近区分

不交换相近任务日期

### 06 任务复用

按旧偏好写出真实文件

## 运行链

任务 JSON → 两款智能体适配器 → 原始回复 / 帧 / 文件 → 确定性检查项 → 六维分数、逐项原因和 SVG 雷达图。缺证据不得分；口头称已写文件，仍须核对文件内容。

## openKylin 3.0 / 12 例真实重复运行

KylinBot 0.7.5 与 OpenClaw 2026.9.6 双实装；v0.2.0 包已在 openKylin 经 apt 安装。下表用同一三批原始证据按 v0.2.1 代码离线重算，未重跑智能体。相同数据与配置，批前恢复干净记忆状态；每批每款 12 例、28 步。

| 批次 / run ID      | KylinBot: 分数 / 完成 / 超时 | OpenClaw: 分数 / 完成 / 超时 |
|------------------|------------------------|------------------------|
| 1 / 92ae7d35ea9f | 31.95 / 21/28 / 3      | 40.28 / 26/28 / 2      |
| 2 / abe90652770c | 40.28 / 28/28 / 0      | 34.72 / 28/28 / 0      |
| 3 / 5ad3c72309be | 30.56 / 28/28 / 0      | 34.72 / 28/28 / 0      |

三批总分均值 / 样本标准差：KylinBot 34.26 / 5.26，完成 77/84 步、3 次 TimeoutError；OpenClaw 36.57 / 3.21，完成 82/84 步、2 次 TimeoutError。旧严格口径 OpenClaw 首批 31.94、均值 33.79 / 1.61。均为智能体分数，非评委分。

4 分 47 秒 openKylin 桌面视频展示真实双智能体环境与历史六例运行；上表 12 例复跑有独立的去敏报告与摘要。

# 从证据到可解释分数

四类检查：回复 JSON 字段、产物 JSON 字段、禁用值是否出现在回复或文件，以及禁用值是否进入可观察的记忆文件或 SQLite 记录。每项报告 pass / fail / missing 与来源。六维各自归一，再取均值。

## 任务书评分项

|          |     |                   |
|----------|-----|-------------------|
| 任务定义与通用性 | 15% | 六项跨会话任务与统一接口      |
| 数据设计质量   | 25% | 六维各两例、虚构变体、行动核验   |
| 自动评分能力   | 25% | 原始证据、结构化判断与原因     |
| 稳定性与可复现性 | 15% | 三批同指纹复跑、隔离、错误与完成率 |
| 指标完整性    | 10% | 六维分、总分、JSON、雷达图   |
| 创新与工程落地  | 10% | 回复 + 记忆 + 文件联合裁决  |

## 重复口径与边界

n=3 批；每批每维 2 例，两个智能体各 28 步。仅汇总同一数据、各智能体相同配置指纹及相同评分器版本的完整运行；逐维与总分报告均值、样本标准差，逐步统计完成率与 TimeoutError。历史六例和替身结果不混算。

新规则仅接受纯 JSON 或无外围正文的唯一完整 json 围栏；首批 OpenClaw 两项 fail→pass，其余 148 项不变。三批前均恢复并核验干净记忆状态；同一台 VM、每维两例、模型温度未显式固定，不能认定稳定排名或统计显著性。原始证据私下保留。

## 版本与参与

v0.2.1 Release 与 .deb、Ubuntu CI、离线摘要与逐项审计、贡献指南与 Issue 入口。v0.2.1 仅通过 Ubuntu 构建检验，尚未在 openKylin 安装；真机运行发生于 v0.2.0。